

CLOUD NATIVE

OLLY

LLM의 비용 · 품질 · 속도를 실시간으로 보는 계기판

OpenTelemetry

Prometheus

Jaeger

Grafana

Kubernetes

오픈소스SW분석(클라우드) 5조

최호준(32215116) | 이용찬(32213336) | 박주희(32221902) | 조하은(32234364)

왜 필요한가?



LLM 도입 급증

챗봇 · 문서요약 · 코드 어시스턴트
기존 서비스에 LLM 기능을
많이 붙이는 추세



운영 복잡도 증가

비용이 갑자기 튀거나
LLM 답변 품질이 흔들려도
원인을 바로 못 찾음



기존 모니터링의 한계

"HTTP 200 OK"이어도 답이 틀릴
수 있음

토큰·프롬프트·모델별 추적이
기존 APM(Application
Performance Monitoring)에는
없음

"LLM 배포를 했는데, 운영 가시성이 부족한 상태"

문제 상황: 운영사 & 사용자

운영사 관점

LLM 품질 평가의 어려움

LLM은 HTTP 200이어도 잘못된 답을 낼 수 있어서,
기존 APM을 통한 응답 성공/실패 추적만으로는
LLM 응답 품질을 평가하기 어려움

병목 지점 파악의 어려움

프롬프트→모델→후처리→재호출 구조에서
느려지는 원인이 모델인지, 네트워크인지 파악 불가

사용자 관점

응답 속도 일관성 부족

같은 질문이라도 수초~수십초까지
차이 나는 응답 속도로 인해,
체감 품질 불안정

답변 신뢰도 부족

할루시네이션 구분 어렵고
결과를 그대로 사용하기 불안함

아이디어 + 서비스 목표

해결 아이디어

**LLM 전용
Observability 기반 서비스**



MVP 목표

- ✓ 모델/기능별 비용 가시화
- ✓ 요청 단위 병목 지점 추적
- ✓ 실시간 알림

현장에서 자주 나오는 질문들

"어제 왜 비용이
2배가 됐지?"

"어떤 기능이 토큰을
가장 많이 쓰지?"

"OpenAI가 느린 것인가,
우리 RAG가 느린 것인가?"

"할루시네이션이
어디서 시작된 거지?"

→ 이 질문들에 답할 수 있는 서비스를 만드는 것이 목표

CNCF 기술 스택

OpenTelemetry

계측 표준

- LLM 호출에 대해 다양한 정보를 표준 형태로 기록
- 벤더 중립, 프레임 워크 무관

CNCF Incubating

Prometheus

메트릭 저장

- 토큰·비용·에러율 시계열 데이터로 저장
- PromQL 쿼리 · Alertmanager

CNCF Graduated

Jaeger

분산 서비스 간 요청 경로 추적

- RAG 파이프라인 단계별 병목 시각화
- 워터폴 뷰 · 적응형 샘플링

CNCF Graduated

Grafana

통합 시각화

- 메트릭+트레이스+로그 통합 조회
- 동적 필터링 · 분석 워크플로

NOT CNCF

Kubernetes

오케스트레이션

- 전체 스택 선언적 배포/확장
- Helm 기반 원클릭 운영

CNCF Graduated

왜 이 기술 조합인가? (기술적 타당성)

"유명해서"가 아니라 "요구사항 적합성"

OTel 벤더 중립 계측 표준 → 장기 운영 유연성 확보

Prometheus 시계열 + PromQL → 비용/성능 쿼리에 최적
Grafana와의 네이티브 연동성 Good

Jaeger Waterfall View 기반 병목 분석
→ LLM 체인 디버깅에 유리함

K8s 선언적 배포/확장 → 관측 스택 운영 자동화

K8s · Prometheus · Jaeger = Graduated | OTel = Incubating

벤더 종속 vs OTel (벤더 중립)

⚠ 프레임워크 종속

LangChain SDK로만 계측
→ 직접 API 전환 시 계측 전면
재개발

→ OTel 기반이면 백엔드만
교체, 계측 유지

⚠ 프록시 종속

외부 프록시 필수 경우 구조
→ 망분리/보안 요구 시 유지
곤란

→ OTel + Collector로
내부 정책 맞춤 라우팅

⚠ 저장소 종속

특정 벤더 쿼리에 강하게 의존
→ 대시보드/알림 이식 어려움

→ 표준 속성 기반이라
저장소 교체해도 지표 유지

유사 솔루션 비교

항목	LangSmith	Helicone	Arize Phoenix	OLLY 서비스
운영 형태	SaaS 중심	SaaS / 프록시	오픈소스 + SaaS	완전 자체 호스팅 -> 데이터 주권 확보
프레임워크 종속성	LangChain 친화	프레임워크 무관	프레임워크 무관	프레임워크 무관
계측 방식	자체 SDK	외부 프록시 기반 경유	SDK + 일부 OTel	OTel 네이티브
데이터 주권	LangSmith 서버에 저장	외부 전송 가능성 존재	선택 가능	조직 내부에 보관
데이터 분석 용이	제한적	중간	중간	용이 (PromQL 기반)

Arize Phoenix

→ 우리 서비스와 가장 유사하지만, 자체 SDK가 섞여있어 완전한 벤더 종립이 아니며
저장소와 시각화가 자체 도구에 묶여있어 Prometheus/Grafana 같은 범용 도구로의 확장이 제한적

차별점 3가지



데이터 주권

완전 자체 호스팅

프롬프트/응답이
외부 SaaS를 거치지 않음

금융·의료·공공 등 외부 전송
제약이 큰 조직에서도 적용 가능



벤더 중립 계측

OTel 네이티브

특정 프레임워크/플랫폼에
묶이지 않음

LangChain → 직접 API 전환 시에도
관측 파이프라인 유지



기존 인프라 재사용

Prometheus/Grafana 직접 통합

이미 쓰는 모니터링 체계에
LLM 지표를 바로 연결

별도 SaaS 학습 비용 없음

Cloud Native LLM 관측성 플랫폼 — 기술 아키텍처

① 계측



OTel SDK 삽입

핵심 수집 지표

- TTFT (첫 토큰 응답시간)
- ITL (토큰 간 지연시간)
- 토큰 사용량 (입력/출력)
- 추정 비용 (모델/기능별)
- 에러율 · 할루시네이션 점수

② 수집 / 가공

OpenTelemetry Collector

PII 마스킹

비용 메타 추가

프로세서 파이프라인

③ 저장

Prometheus

메트릭 저장
토큰 · 비용 · 에러율 · 레이턴시

Jaeger

트레이스 저장
RAG 파이프라인 단계별 추적

Loki

로그 저장
프롬프트 · 응답 로그

④ 시각화 / 알림

Grafana

통합 대시보드
비용 · 성능 · 품질 실시간 조회

비용 대시보드

트레이스 뷰

Evaluation API

품질 점수 비용기 평가
(할루시네이션 · 관련성)

확장 (선택)

Alertmanager

임계치 알림
중복 제거 · 그룹화 · 라우팅

Notification Channels

Slack

Discord

Email

PagerDuty

경제/기술 타당성 + 결론

💰 경제적 타당성

개발비용

- CNCF 오픈소스 기반 → 라이선스 비용 0

운영편익

- 토큰 낭비/불필요 호출 탐지 → LLM API 비용 직접 절감
- 장애 발견시간(MTTD) 수분 이내 → 장애 확산 차단
- 모델별 비용 대비 품질 비교 → 데이터 기반 모델 선택

🔑 기술적 타당성

처음부터 다 만드는 것이 아님

검증된 컴포넌트 조립 + LLM 특화 로직 추가

4인 역할 분담 (병렬 개발 가능)

- ① 계측 SDK / 샘플 앱 연동
- ② Collector 파이프라인 / PII 마스킹
- ③ 대시보드 / 알림 템플릿
- ④ 배포 자동화 (Helm) / 문서화

결론

LLM 시대의 운영 핵심은 "모델 성능"뿐만이 아니라 "운영 가시성"까지

CNCF 기반 오픈소스 스택으로 비용 · 품질 · 속도를 동시에 관리하는 실무형 관측성 플랫폼을 제안

Thank you & QnA

오픈소스SW분석(클라우드) 5조

최호준(32215116) | 이용찬(32213336) | 박주희(32221902) | 조하은(32234364)